Классификация рамановских спектров с использованием методов машинного обучения

Команда «Чиназес», март 2026

Введение

Задача: Проект ориентирован на разработку программы, анализирующей молекулярный состава веществ по спектрам комбинационного рассеяния света.
Цель: Разработка ML-модели для классификации спектров на 3 группы

- Control
- Endo
- Exo

Данные

Описание данных

- **Формат:** Набор текстовых файлов (результаты рамановского картирования).
- **Состав файла:** Координаты измерения (X, Y) + интенсивности сигнала (волновое число).
- **Представление:** Матрица спектров
- **Метаинформация (в названии файла):** Экспериментальная группа, тип ткани, центр лазера.
- **Особенности:** Наличие характерных пиков интенсивности (молекулярные колебания).

Описание данных

На рисунке представлены случайные спектры из разных файлов датасета. Видны характерные пики интенсивности, соответствующие различным молекулярным колебаниям.

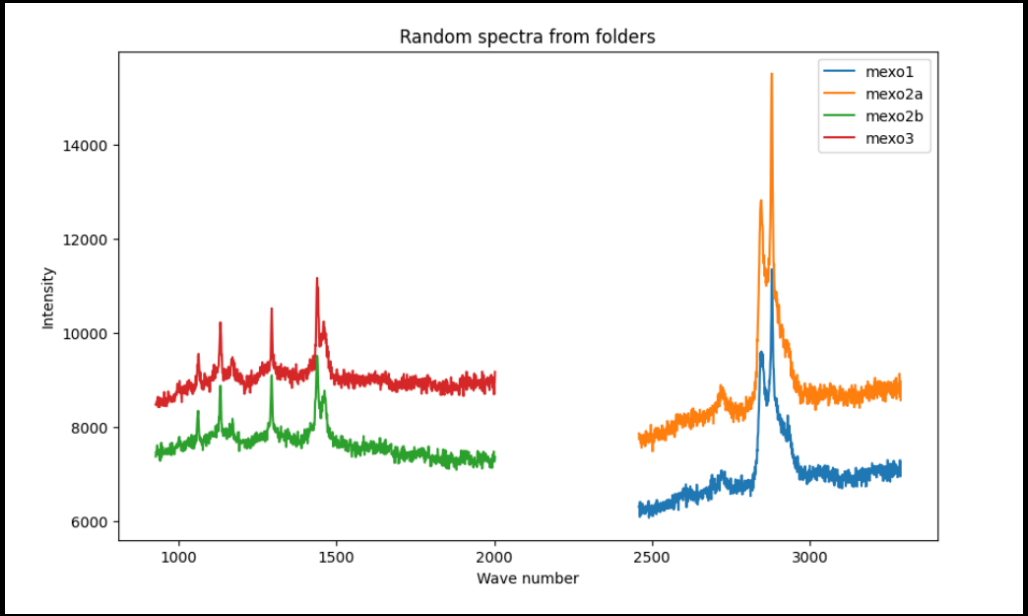

Предобработка данных

- **Формирование датасета:** Автоматическая загрузка файлов в матрицу.
- **Кодирование признаков:**
  Целевая переменная → Label Encoding.
  Признаки center и cells → One-Hot Encoding.
- **Масштабирование:**
  Стандартизация (StandardScaler).
  L2-нормализация.
- **Снижение размерности:** Метод главных компонент (PCA).

Визуализация в пространстве PCA

После применения PCA (Principal Component Analysis) данные были визуализированы в пространстве первых двух главных компонент. Несмотря на частичное перекрытие классов, на графике наблюдаются характерные структуры распределения спектров различных экспериментальных групп.

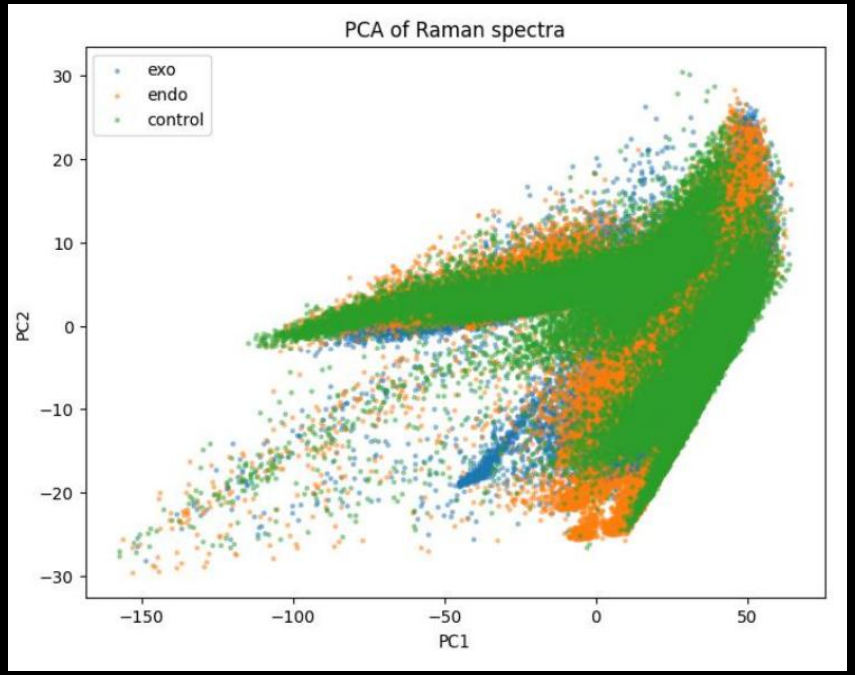

Модели и метрики

Используемые алгоритмы

Мы использовали три модели:

- **Random Forest:** Ансамбль деревьев - устойчива к переобучению.
- **LightGBM:** Градиентный бустинг (ориентирован на вычислительную эффективность).
- **XGBoost:** Градиентный бустинг (ориентирован на высокую точность).

Метрики качества

Модели после обучения были протестированы на независимой тестовой выборке.

Полученные результаты показывают, что методы градиентного бустинга обеспечивают наилучшую точность классификации.

Модель	Accuracy	Macro f1
Random forest	0.90	0.90
LightGBM	0.935	0.93
XGBoost	0.935	0.94

Вывод

Вывод

В работе был разработан pipeline анализа рамановских спектров, включающий предобработку данных, снижение размерности методом PCA и обучение моделей машинного обучения. Эксперименты показали, что модели LightGBM и XGBoost достигают точности около 93– 94%, что подтверждает эффективность предложенного подхода для классификации спектральных данных.