Классификация рамановских спектров с использованием методов машинного обучения

Команда: Чиназес

1. Введение

Рамановская спектроскопия позволяет анализировать молекулярный состав веществ по спектрам комбинационного рассеяния света. Методы машинного обучения позволяют автоматически обрабатывать такие спектральные данные большой размерности.
Целью работы является разработка модели машинного обучения для классификации рамановских спектров на три группы: **control**, **endo** и **exo**.
Для решения задачи был реализован pipeline обработки данных, включающий предобработку спектров, снижение размерности и обучение моделей машинного обучения.

2. Описание данных

Исходные данные представляют собой набор текстовых файлов, содержащих результаты рамановского картирования. Каждый файл включает координаты измерения и интенсивности сигнала для различных значений волнового числа.Каждая пара координат (X, Y) соответствует одному спектру. После обработки данные представляются в виде матрицы:

X ∈ ℝ^(n_spectra × n_channels), где:

- n_spectra — количество спектров
- n_channels — число каналов спектра.

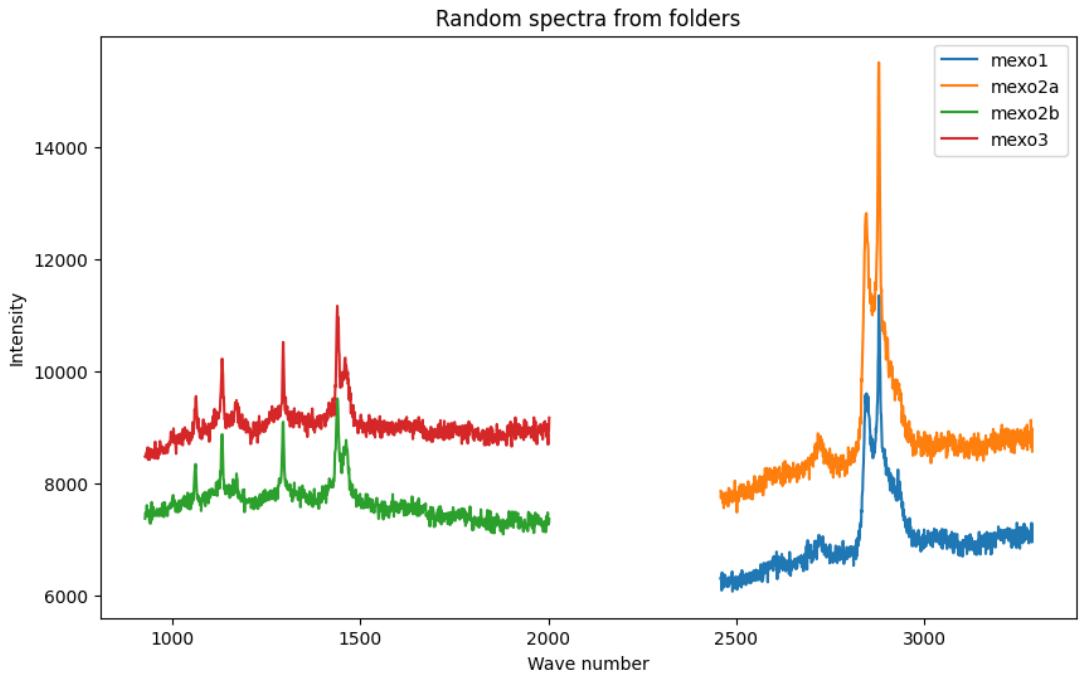

На рисунке представлены случайные спектры из разных файлов датасета. Видны характерные пики интенсивности, соответствующие различным молекулярным колебаниям.

3. Предобработка данных

Рамановские спектры имеют высокую размерность и могут содержать шумы и экспериментальные артефакты. Для подготовки данных к обучению моделей был реализован pipeline предобработки.

Формирование датасета

Все файлы автоматически загружались и преобразовывались в матрицу спектров. Для каждого спектра дополнительно извлекалась метаинформация: экспериментальная группа, тип ткани и центр лазера.

Кодирование категориальных признаков

Категориальные признаки преобразовывались в числовой формат. Целевая переменная кодировалась методом Label Encoding, а признаки center и cells — методом One-Hot Encoding**.**

Масштабирование и нормализация

Спектральные признаки стандартизировались с использованием StandardScaler, после чего выполнялась L2-нормализация каждого спектра. Это позволяет анализировать форму спектра независимо от абсолютной интенсивности сигнала.

Снижение размерности

Для уменьшения размерности спектров применялся метод главных компонент **(**PCA**).** Преобразованные PCA-компоненты использовались в качестве признаков для обучения моделей машинного обучения.

4. Анализ структуры данных

После применения PCA данные были визуализированы в пространстве первых двух главных компонент.

Распределение спектров в пространстве PCA

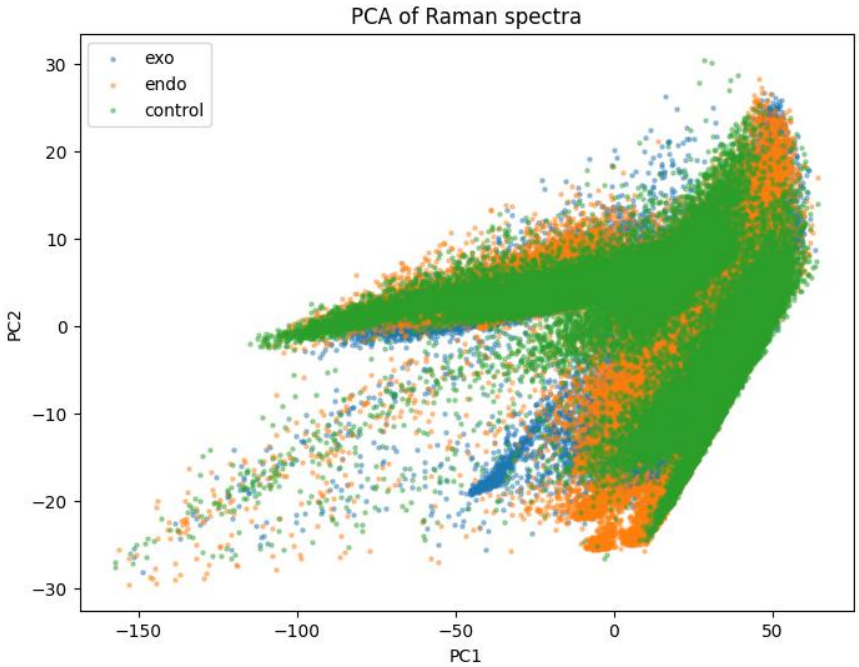

Несмотря на частичное перекрытие классов, на графике наблюдаются характерные структуры распределения спектров различных экспериментальных групп.

5. Модели машинного обучения

Для решения задачи многоклассовой классификации были обучены три модели машинного обучения:

- Random Forest
- LightGBM
- XGBoost

Random Forest представляет собой ансамбль решающих деревьев, обученных на случайных подвыборках данных. Алгоритм устойчив к переобучению и хорошо работает с высокоразмерными признаками.

LightGBM и XGBoost являются алгоритмами градиентного бустинга, широко применяемыми для задач классификации табличных данных благодаря высокой точности и эффективности.

6. Результаты

Модели были обучены на тренировочной выборке и протестированы на независимой тестовой выборке.

Модель	Accuracy	Macro F1
Random Forest	0.90	0.90
LightGBM	0.935	0.93
XGBoost	0.935	0.94

Полученные результаты показывают, что методы градиентного бустинга обеспечивают наилучшую точность классификации.

7. Вывод

В работе был разработан pipeline анализа рамановских спектров, включающий предобработку данных, снижение размерности методом PCA и обучение моделей машинного обучения.
Эксперименты показали, что модели LightGBM и XGBoost достигают точности около **93–94%**, что подтверждает эффективность предложенного подхода для классификации спектральных данных.